



INSTITUTO FEDERAL DA PARAÍBA - IFPB

Unidade Acadêmica de Informação e Comunicação

Mestrado Profissional em Tecnologia da Informação

Disciplina: **Ciência de Dados**

Docente: Damires Souza e Alex Cunha

Período: 2026.1

Equipe/responsável:

Planejamento para projeto de Ciência de Dados

1. Compreensão do negócio/domínio do problema

- i. **Contextualização:** escreva um ou dois parágrafos apontando o **contexto do problema/domínio de aplicação/situação da empresa**.
- ii. Há especialista do domínio para ajudar no projeto? Se sim, qual a sua função?
- iii. **Problema de ciência de dados:** defina explicitamente qual é o problema de análise/ciência de dados a ser atacado dentro do contexto de problema/negócio/aplicação descrito.

2. Fontes de dados

- a. Indique a(s) fonte(s) de dados a ser(em) usada(s) e onde estão disponíveis.
- b. Necessitará de dados primários e/ou secundários? Comente.
- c. Dê exemplos de dados a serem usados.
- d. Há previsão de uso de dados sensíveis? Se sim, justifique.

3. Coleta de dados

- a. Há necessidade de instrumento de coleta de dados (e.g., formulário)? Se sim, o que se deseja obter com ele?

4. A proposta está dentro do seu tema de mestrado?

5. Alguma informação ou aspecto adicional específico ao seu trabalho?

i. Contextualização

Documentos médicos, diagnósticos e procedimentos de saúde costumam ser descritos com linguagem técnica, termos especializados, siglas e abreviações próprias da área médica. Essa linguagem pode dificultar a compreensão por pessoas que não atuam na saúde, independentemente do nível de escolaridade.

Bases públicas do SUS, como o DataSUS/SIGTAP, e vocabulários controlados da área da saúde permitem analisar essas descrições de forma organizada. O foco deste projeto é construir um dataset para representar e classificar a complexidade técnico-linguística de diagnósticos e procedimentos médicos.

ii. Especialista do domínio

Este projeto não conta com a participação direta de um especialista do domínio no escopo da disciplina. Serão utilizadas fontes oficiais e públicas da área da saúde, como DataSUS/SIGTAP, CID-10 e DeCS/MeSH. A validação por profissionais de saúde poderá ser realizada em fases futuras da pesquisa.

iii. Problema de Ciência de Dados

O problema deste projeto consiste em construir um dataset rotulado para classificar diagnósticos e procedimentos médicos em níveis de complexidade técnico-linguística: baixa, média ou alta.

De forma mais específica, pretende-se:

- Coletar descrições oficiais de diagnósticos e procedimentos médicos;
- Extrair atributos textuais, como quantidade de palavras, quantidade de caracteres, presença de siglas e quantidade de termos técnicos;
- Criar uma variável alvo de complexidade por meio de regras heurísticas;
- Aplicar uma árvore de decisão para interpretar quais atributos mais influenciam a classificação;
- Gerar visualizações para apoiar a análise dos resultados.

O diferencial do projeto está em construir um dataset próprio a partir de fontes públicas e aplicar técnicas de ciência de dados para transformar descrições médicas em atributos analisáveis.

2. Fontes de dados

a. Fontes utilizadas

Fontes de dados públicas:

- DataSUS/SIGTAP - códigos, nomes e classificações de procedimentos do SUS:
<https://sigtap.datasus.gov.br/>
- CID-10/DataSUS - códigos, capítulos e descrições de diagnósticos:
<https://tabnet.datasus.gov.br/>
- DeCS/MeSH (BIREME/BVS) - vocabulário controlado de termos da área da saúde:
<https://decs.bvsalud.org/>

As fontes serão acessadas por download, consulta pública ou extração automatizada, conforme a disponibilidade de cada base.

b. Dados primários e secundários

Serão utilizados exclusivamente dados secundários, obtidos de bases públicas e oficiais. Não haverá aplicação de questionários, entrevistas ou coleta direta com pacientes.

c. Exemplos de dados utilizados

Cada linha do dataset corresponderá a um diagnóstico, procedimento ou termo médico. Exemplos de campos:

Campo	Tipo	Exemplo
codigo	texto	J15.9 ou 0301010013
tipo_registro	categoria	diagnóstico ou procedimento
descricao	texto	Pneumonia bacteriana não especificada
fonte	categoria	CID-10 ou SIGTAP
capitulo_ou_grupo	categoria	Doenças do aparelho respiratório
qtd_palavras	inteiro	4
qtd_caracteres	inteiro	38
qtd_termos_tecnicos	inteiro	2
possui_sigla	booleano	Sim / Não
possui_abreviacao	booleano	Sim / Não
complexidade (target)	categoria	baixa média alta

d. Dados sensíveis

Não há previsão de uso de dados sensíveis. As fontes utilizadas contêm códigos, descrições, classificações e vocabulários técnicos, sem identificação de pacientes, CPF, nome, endereço ou qualquer dado pessoal.

3. Coleta de dados

a. Instrumento de coleta

Não haverá necessidade de instrumento de coleta, pois os dados serão obtidos diretamente de bases públicas oficiais. A coleta será feita por download, consulta pública ou scripts em Python.

A etapa de coleta e preparação incluirá:

- Extração dos arquivos ou tabelas públicas;
- Padronização dos nomes das colunas;
- Integração entre bases;
- Tratamento de valores ausentes e duplicidades;
- Criação de atributos derivados;
- Rotulagem heurística da variável de complexidade.

4. A proposta está dentro do seu tema de mestrado?

Sim, a proposta está relacionada ao tema do mestrado, mas não corresponde ao projeto completo. O mestrado envolve o Traduz Saúde, voltado à simplificação da linguagem médica para uma linguagem mais simples e acessível ao paciente. Nesta disciplina, o foco será construir um dataset para analisar a complexidade técnico-linguística de diagnósticos e procedimentos médicos. Assim, o trabalho contribui com o tema do mestrado, mas mantém o escopo da disciplina de Ciência de Dados.

5. Informações adicionais

O projeto será desenvolvido em Python, com uso de bibliotecas voltadas para ciência de dados, como pandas, numpy, scikit-learn, matplotlib e seaborn, em ambiente Google Colab.

As principais etapas incluem:

- Extração e limpeza dos dados;
- Preparação e transformação dos atributos;
- Análise exploratória;
- Visualização dos dados;
- Classificação com árvore de decisão;
- Avaliação do modelo por matriz de confusão e métricas simples, como acurácia.

Também será feita análise de outliers, pois podem existir descrições muito curtas, descrições muito longas, procedimentos raros, registros duplicados ou itens com quantidade elevada de termos técnicos. Esses casos serão identificados por estatísticas descritivas e gráficos, como boxplots. A remoção não será automática, pois alguns valores extremos podem representar informações relevantes na área da saúde.

Como limitação, reconhece-se que a variável de complexidade será criada inicialmente por regras heurísticas. Assim, os resultados devem ser interpretados como uma análise exploratória da complexidade textual de diagnósticos e procedimentos médicos, e não como medida definitiva de compreensão real por parte dos pacientes.